

ЛОКАЛЬНЫЕ LLM · ВАШЕ ЖЕЛЕЗО · ВАШИ ДАННЫЕ

4 000 000 файлов. 40
параметров. Один правильный
ответ.

LlamaToaster — прибор, который находит его.

- Локальный инференс не должен требовать опыта специалиста по llama.cpp.

БОЛЬ №1 — ВЫБОР МОДЕЛИ

Каталог из 3 000 000 моделей невозможно прочитать

**~3 000
000**

моделей на Hugging Face

~200 000

из них — GGUF, готовые к
llama.cpp

**≈4 000
000**

файлов, если пересчитать все
квантования

- Каталог растёт каждую неделю — «лучшая» модель устаревает уже к следующей.
- Поэтому выбирают по слухам: «в одном треде на Reddit сказали, что эта хорошая».

БОЛЬ №2 — НАСТРОЙКА

Выбор — это один стог сена. Настройка — второй, побольше.

Одна ошибка в параметрах — тихая потеря качества или падение.

- Размер контекста · число офлоад-слоёв · квантование KV-кэша (9 вариантов) · flash_attn · MTP / draft-декодирование · batch и ubatch · потоки · сборка llama.cpp...
- Каждый параметр влияет на остальные; одного конфига «на все GPU» не существует.
- Ручной путь: скопировать чужой конфиг → менять наугад → пробовать, пока «почти работает», — или сдаться.

НАСТОЯЩЕЕ УЗКОЕ МЕСТО

С железом почти всегда всё было в порядке — подводит слой выбора.

- Побеждает первый конфиг, который не упал, а не лучший.
- Сложность не преодолевается — она просто отсеивает людей.
- Пользователи уходят с мыслью «локальный инференс не для меня», хотя не хватало именно инструмента выбора.

ПОЧЕМУ ИМЕННО СЕЙЧАС

Модели развиваются быстрее, чем кто-либо успевает следить, — и наконец перешли черту

- Новые поколения выходят каждые несколько недель: Qwen, Llama, Mistral, Gemma... совет месячной давности уже устарел.
- Qwen 3 8B / 27B $\approx$ качество флагманов прошлого поколения — на обычном ПК.
- Проприетарные API: сбои, отказы, изменение цен — вы ничего из этого не контролируете.
- Данные остаются на вашей машине, в стороне от логов провайдеров.
- Не хватает одного — решить, что запускать.

НЕДОСТАЮЩАЯ ПОЛОВИНА

Качество измеряют до бесконечности. Производительность — чёрный ящик.

Десятки лидербордов оценивают «умность» — почти ничего не показывает, что вы получите на практике.

- LMArena, Open LLM Leaderboard, MMLU, GPQA, HumanEval, MT-Bench... каждый релиз оценивают ночь за ночью.
- Но почти никто не отвечает на вторую половину: **ток/с, задержка, реально доступный контекст — на ВАШЕМ железе.**
- Миллионы файлов и горы оценок качества — а производительность по-прежнему на слухах и переборе.

МИФ О ДАТАЦЕНТРЕ

LLM не нужен датацентр — нужна модель подходящего размера

Многие думают, что запуск LLM означает аренду серверной фермы.

- Реальность: небольшая современная квантованная модель работает даже на скромном VPS.
- Она не тянет на флагман — и не должна. Эмбеddинг или speech-to-text решают реальные повседневные задачи на нескольких гигабайтах.
- **Не будешь же нанимать доктора наук, чтобы решить уравнение с одним неизвестным.** Инструмент — по задаче.
- Отпугивает людей не железо, а миф.

РЕШЕНИЕ

Оркестратор, который отвечает, а не просто измеряет

- Одна команда подключает любую машину с GPU или CPU — pull-only, ноль открытых портов, никаких «танцев с файрволом».
- Вы задаёте намерение: цель × нагрузка × целевой контекст. Сетка строится сама, прогон выполняется сам.
- На выходе — карточки профилей: **Max Speed · Balanced · Max Context · Low Memory**, и у каждой понятное обоснование.
- Плюс подтверждённые потолки контекста, «колено» конкурентности и честное сравнение моделей между собой.

ОБЕЩАНИЕ ТОСТЕРА

Намерение на входе. Решение на выходе.

Настройка — пять минут сегодня вечером. К утру: **«запускай вот эту конфигурацию»** — а не «разбирайся сам».

- Хватит тюнинга. Начинайте выпускать.

ПОЧЕМУ КАРТОЧКЕ МОЖНО ВЕРИТЬ

Каждое число несёт свои методы

- Гейты допуска — стабильность, подозрительные замеры, порог `stddev` — отправляют таймер-баги вроде `1e6 tok/s` в мусор, а не в среднее.
- Память оценивается по реальному размещению тензоров GGUF — ловит конфиг, который сообщает «31/31 слоёв офлоада», а на деле тихо работает в системной памяти.
- Сравнения честны по построению: другая машина, сборка или GPU отклоняют участника, а не вердикт.
- Экспорт защищён от подмены: хэш на каждую строку, версии методологии никогда не смешиваются.

для кого

Для всех, кто запускает модели локально

- Один GPU в домашнем ПК — энтузиасты, создатели контента, исследователи.
- Команды с разнородными машинами и без общего «фольклора».
- Все, кто публикует воспроизводимые цифры локального инференса.

ЧТО МЫ ПРОСИМ

Запустите свою машину сегодня вечером

<https://github.com/noname9006/LlamaToaster>

- Одна команда подключает машину — без проброса портов и ручной сборки (llama.cpp ставится из веб-интерфейса).
- Включите «обмен с сообществом» (k-анонимизация) — и весь каталог начнёт искать за всех.
- Поставьте звезду, пока проект молодой.